Amazon 园艺商品评分预测与 Top-10 推荐实验报告

1 研究目标与实验结论

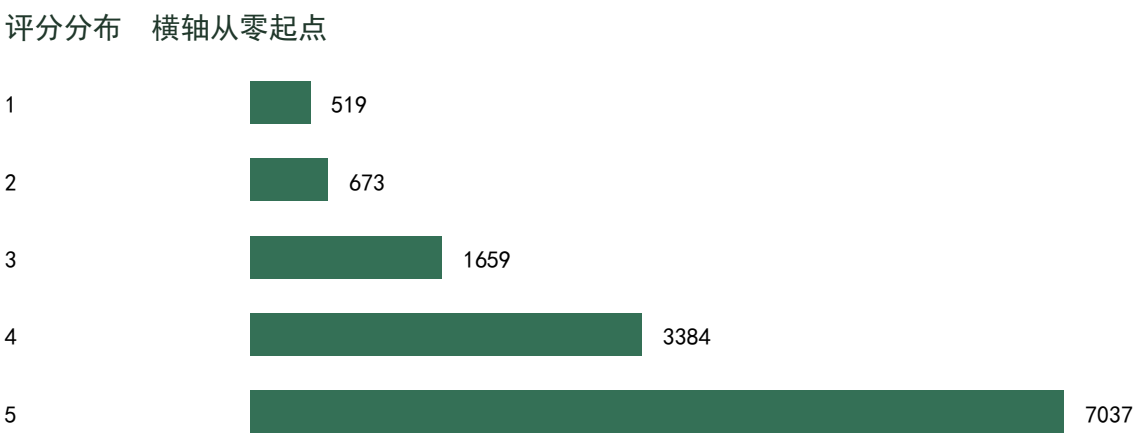
本项目使用 Amazon Patio, Lawn and Garden 5-core 数据，完成按用户划分、评分预测和 Top-10 推荐。实验比较全局均值、偏置基线、物品协同过滤、显式反馈矩阵分解，并增加热门推荐作为排序对照。

在训练集内部验证后，评分任务预选模型为 Bias，排序任务预选模型为 Popularity。下表展示各模型最终测试结果。测试集只用于最终比较，不参与选参或选择部署模型。

2 数据与预处理

原始文件包含 13,272 条去重后记录、1,686 位用户、962 件商品。矩阵密度为 0.8183%，平均评分为 4.1865。评分日期为 2000-04-05 至 2014-07-22。每位用户至少 5 条记录，每件商品至少 5 条记录。

程序校验用户 ID、商品 ID 和 1–5 整数评分。相同用户与商品只保留最新记录，本次移除 0 条重复记录。评论正文、摘要、时间和 helpful 字段随记录保留。模型仅使用用户 ID、商品 ID、评分，不使用测试评论或测试评分构造特征。数据不包含商品元数据与图像向量，因此推荐结果以 ASIN 展示。helpful 字段保留原样，未用于建模。



3 可复现实验协议

外层随机种子为 42，逐用户打乱后取 floor(0.8×n) 条作为训练集，其余作为测试集。当记录数不能整除时，实际比例会偏离 80%。不为保证测试商品在训练集中出现而交换样本。

数据子集	记录数	用途
train	10,054	外层训练及最终拟合
test	3,218	最终评分与排序评估
fit	7,552	内层参数训练
validation	2,502	选参及预选模型

实际外层训练占比为 75.75%。fit 与 validation 是 train 的不相交子集，各用户在 train 内再按相同规则进行 80%/20% 划分，内层种子为外层种子加一。选参完成后，在完整 train 上重新训练，再评估 test。

外层训练中完全未出现的目录商品数为 2，对应测试记录 10 条。商品目录由原始数据的唯一 ASIN 构成，假设目录已知；目录使用商品标识，不使用任何测试交互标签。冷商品使用均值或偏置回退，其潜在因子为零。对完全未知的外部用户或商品评分查询，返回训练均值。

4 算法

GlobalMean 对所有用户与商品预测训练集均值，作为最低复杂度对照。排序同分时按 ASIN 字典序，故其 Top-10 指标只作为对照。

Bias 使用 r_hat(u,i)=μ+b_u+b_i，固定 μ 为训练均值，交替求解带 L2 正则的用户偏置和商品偏置。优化目标为已观测评分上的平方误差加 reg×(用户偏置平方和+商品偏置平方和)。

ItemKNN 先拟合 Bias，将已观测评分减去 μ+b_u+b_i，缺失位置置零。物品相似度为残差向量余弦相似度，再乘共同评分人数 c/(c+shrinkage)。只保留正相似度，对每个目标商品，从该用户已评分商品中选择最多 k 个邻居。预测为偏置基线加邻居残差的加权平均；没有可用邻居时回退到偏置基线。此实现使用完整残差向量范数，属于带收缩的残差余弦变体，不声称严格复现 Sarwar 原论文所有细节。

MFALS 先固定 Bias，再优化 r_hat(u,i)=μ+b_u+b_i+p_u·q_i。目标只包含已观测评分的平方误差，加 factor_reg×(用户因子平方和+商品因子平方和)，交替求解两个因子矩阵的正则最小二乘。每个用户和商品的正则系数固定，不按评分数缩放；缺失条目不当作零评分参与目标。它是显式反馈 ALS，不是隐式反馈 ALS。

Popularity 只按训练集中商品评分次数排序，不使用评分值，是独立的排序基线，因此不报告其 MAE 与 RMSE。

5 指标定义

评分指标：MAE=mean(|r-r_hat|)，RMSE=sqrt(mean((r-r_hat)^2))。评分预测裁剪到 [1,5]，排序使用未裁剪得分以保留大小关系。

排序候选为整个已知商品目录减去该用户训练集中已评分商品，不采样负例。相关集合 T_u 为该用户所有测试商品，不额外筛选 rating>=4。推荐列表 L_u 长度为 10，P_u=|L_u intersect T_u|/10，R_u=|L_u intersect T_u|/|T_u|。Precision 和 Recall 分别对用户宏平均。按课程公式 F-measure=2×P_macro×R_macro/(P_macro+R_macro)。另存 macro_f1，即逐用户 F1 的平均，避免混淆这两个定义。

NDCG 使用二值相关性，DCG@10=sum(hit_j/log2(j+1))，IDCG 为 min(10,|T_u|) 个相关项的理想 DCG，再对用户取平均。目录覆盖率为所有推荐列表中不同商品数量除以目录商品总量。同分推荐按 ASIN 字典序确定，保证重复运行一致。

6 验证与测试结果

各评分模型的参数按验证 RMSE 最小选择。排序任务在这些已选配置与热门基线中，按验证 NDCG 最大预选模型。因此排序结果并非每个算法单独以 NDCG 调参后的上限。完整候选参数、验证指标和用时见 validation_trials.json。

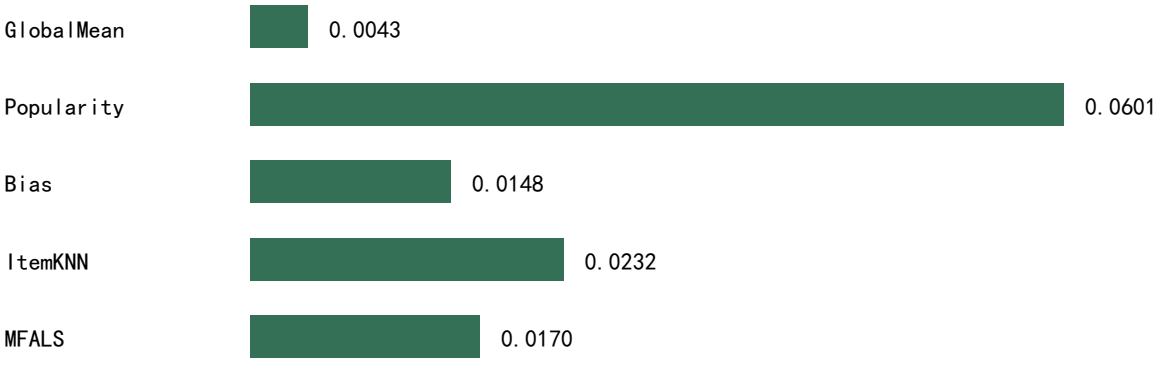
模型	验证 RMSE	验证 NDCG@10	最终参数
GlobalMean	1.108408	0.002927	{}
Popularity	不适用	0.058161	{}
Bias	1.004772	0.018005	{'reg': 5.0}
ItemKNN	1.103214	0.025289	{'neighbors': 10, 'shrinkage': 5.0, 'reg': 15.0}
MFALS	1.018051	0.020861	{'factors': 8, 'factor_reg': 10.0, 'epochs': 20, 'reg': 15.0, 'seed': 42}

模型	MAE	RMSE	P@10	R@10	F-measure	NDCG@10
GlobalMean	0.852193	1.060500	0.001601	0.009559	0.002743	0.004260
Popularity	不适用	不适用	0.017556	0.079844	0.028784	0.060129
Bias	0.741726	0.966929	0.003559	0.020057	0.006045	0.014833
ItemKNN	0.805930	1.106110	0.006406	0.039207	0.011012	0.023166
MFALS	0.773214	0.978459	0.004389	0.024002	0.007421	0.016984

测试 RMSE　越低越好



测试 NDCG@10　越高越好



7 结果分析与局限

本次测试表中 RMSE 最低的模型为 Bias，RMSE=0.966929。这是描述性比较，不据此重新选择超参数。

本次测试表中 NDCG@10 最高的是 Popularity，NDCG@10=0.060129。评分误差与排序指标衡量不同目标，需要分别解释。

数据稀疏且 4－5 星占多数，均值与正则偏置可能具有较强竞争力。模型复杂度更高并不保证在小样本上更好。这是一种可能解释，本实验未通过因果或显著性检验验证。

本次结果来自单次随机划分，未提供置信区间，不能证明模型间差异在所有划分中稳定。逐用户随机划分符合课程建议，但不是严格的时间外推测试，可能让较晚交互参与较早交互预测。随机划分时整条评论一起移动，未读取测试评论进行训练。

未观测商品不等于用户不喜欢，Top-10 指标只根据有限的测试交互计算。全部测试商品视为相关也包含低分商品，这是课程指标口径；若扩展为高分正反馈评估，必须单独报告，不能直接与本表混用。

实现使用稠密矩阵，适合本次 1,686×962 规模，内存随用户数乘商品数增长。更大数据应使用稀疏矩阵和分块候选评分。本项目不使用评论、图像或商品元数据增强特征，后续可在严格训练数据边界内开展这些扩展。

8 复现与提交

运行环境为 Python 3.10+ 与 NumPy。源代码包含数据加载、五种模型、完整评估与报告生成。

```
python -m pip install -r requirements.txt
python -m gardenrec run --config configs/default.json
python -m unittest discover -s tests -v
```

本次运行 Python=3.12.14，NumPy=2.3.5。数据 SHA256 为 119612a8dc9dd6967ef74ea23d447d83e8adbfbe144c9f89b2ba39e72fda077f。manifest.json 记录实际配置、版本和时间；splits/indices.npz 保存固定划分索引。

metrics.json 与 comparison.csv 保存汇总指标；predictions 保存逐条评分预测；per_user 保存逐用户指标；recommendations 保存各用户 Top-10；models 保存不依赖 pickle 的 NPZ 模型。报告和幻灯片使用这些实际运行结果。

提交打包脚本仅包含代码、配置、说明、汇总结果、报告及幻灯片，不包含原始数据、拆分评论或训练模型。提交前在报告和幻灯片中补充组员、学号、分工等课程要求的身份信息。

9 参考文献

Amazon Reviews 2014 数据与字段说明

Sarwar et al. Item-Based Collaborative Filtering Recommendation Algorithms. WWW 2001.

Koren, Bell, Volinsky. Matrix Factorization Techniques for Recommender Systems. Computer 2009.

课程任务来源为 RS-Project-description(2).pdf 的数据划分、评分预测、进阶推荐与提交章节。上述算法为本项目的可复现实验实现，未声称复现参考论文的完整实验。